

Tinh chỉnh LLM theo chỉ dẫn cho bài toán Phân tích Cảm xúc Khía cạnh tiếng Việt

Trần Anh Duy¹, Trương Thế Minh Khánh¹, Nguyễn Văn Tiên¹

¹Khoa Khoa học và Kỹ thuật Thông tin

Trường Đại học Công nghệ Thông tin – ĐHQG TP. Hồ Chí Minh, Việt Nam

{23520389, 23520727, 23521580}@gm.uit.edu.vn

Tóm tắt nội dung

Phân tích cảm xúc dựa trên khía cạnh (Aspect-Based Sentiment Analysis - ABSA) là một bài toán quan trọng trong việc khai thác ý kiến khách hàng từ dữ liệu văn bản. Tuy nhiên, các phương pháp truyền thống dựa trên gán nhãn chuỗi (Sequence Labeling) thường gặp khó khăn khi xử lý các cấu trúc câu phức tạp, các khía cạnh chồng chéo hoặc các khía cạnh ẩn trong tiếng Việt. Trong nghiên cứu này, chúng tôi tiếp cận ABSA như một bài toán tạo sinh chuỗi (Generative Sequence-to-Sequence), trong đó mô hình được hướng dẫn trích xuất trực tiếp các bộ ba thông tin gồm khía cạnh, cảm xúc và đoạn minh chứng. Chúng tôi áp dụng kỹ thuật Instruction Tuning để tinh chỉnh mô hình **Qwen2.5-7B**, kết hợp với QLoRA nhằm giảm yêu cầu về tài nguyên tính toán. Ngoài ra, cơ chế hậu xử lý **Neuro-Symbolic** kết hợp biểu thức chính quy và chuẩn hóa dựa trên luật được đề xuất để đảm bảo tính nhất quán của đầu ra có cấu trúc. Thử nghiệm trên bộ dữ liệu **UIT-ViSD4SA** cho thấy phương pháp đề xuất đạt Micro F1-Score lần lượt là **74.79%** cho trích xuất khía cạnh, **84.36%** cho nhận diện cảm xúc và **65.73%** cho khớp chính xác khía cạnh-cảm xúc.

1 Giới thiệu

Sự gia tăng nhanh chóng của các nền tảng thương mại điện tử tại Việt Nam đã tạo ra một lượng lớn bình luận và đánh giá của người dùng. Những văn bản này thường đề cập đồng thời đến nhiều thuộc tính khác nhau của sản phẩm, kèm theo các đánh giá phản ánh những xu hướng cảm xúc khác nhau. Do đó, phân tích cảm xúc dựa trên khía cạnh (Aspect-Based Sentiment Analysis – ABSA) đóng vai trò quan trọng trong việc khai thác thông tin chi tiết từ dữ liệu ý kiến người dùng.

Phần lớn các nghiên cứu ABSA cho tiếng Việt hiện nay tiếp cận bài toán dưới dạng gán nhãn chuỗi, trong đó mỗi từ được gán nhãn thể hiện khía cạnh hoặc cảm xúc. Cách tiếp cận này cho thấy

hiệu quả trong những trường hợp đơn giản nhưng gặp khó khăn khi xử lý các hiện tượng phổ biến trong dữ liệu thực tế, bao gồm nhiều khía cạnh xuất hiện đồng thời, khía cạnh chồng chéo, hoặc khía cạnh được biểu đạt gián tiếp. Ngoài ra, việc phụ thuộc vào nhãn ở mức từ làm giảm khả năng thích nghi của mô hình khi áp dụng sang các miền dữ liệu mới.

Chúng tôi tiếp cận ABSA tiếng Việt như một bài toán tạo sinh chuỗi (Generative Sequence-to-Sequence), trong đó mô hình được hướng dẫn trích xuất trực tiếp các bộ ba thông tin gồm khía cạnh, cảm xúc và đoạn minh chứng từ văn bản đầu vào. Hướng tiếp cận này cho phép mô hình xử lý trực tiếp mối quan hệ giữa khía cạnh và xu hướng cảm xúc trong câu, đồng thời giảm sự phụ thuộc vào gán nhãn chi tiết ở mức từ. Chúng tôi đánh giá phương pháp đề xuất trên bộ dữ liệu UIT-ViSD4SA và thảo luận các kết quả đạt được trong bối cảnh hạn chế về tài nguyên tính toán.

2 Các nghiên cứu liên quan

2.1 Phân tích cảm xúc khía cạnh cho tiếng Việt

Các nghiên cứu ban đầu về phân tích cảm xúc dựa trên khía cạnh (ABSA) cho tiếng Việt chủ yếu tiếp cận bài toán dưới dạng gán nhãn chuỗi (Sequence Labeling). Nguyen và cộng sự (Nguyen et al., 2021) đã giới thiệu bộ dữ liệu UIT-ViSD4SA và thiết lập các đường cơ sở (baseline) sử dụng BiLSTM-CRF và XLM-RoBERTa, trong đó bài toán được mô hình hóa theo định dạng thể BIO (Beginning-Inside-Outside). Sự xuất hiện của các mô hình ngôn ngữ tiền huấn luyện đơn như PhoBERT (Nguyen et al., 2020) và ViBERT (Nguyen and Vu, 2020) đã cải thiện hiệu năng nhờ khả năng biểu diễn ngữ cảnh tốt hơn. Tuy nhiên, các phương pháp dựa trên gán nhãn chuỗi thường xử lý bài toán theo các kiến trúc dạng đường ống (pipeline), dễ dẫn đến lan truyền lỗi và gặp hạn chế


khi cần biểu diễn các khía cạnh được biểu đạt gián tiếp hoặc chồng chéo trong văn bản. Những hạn chế này đặt ra nhu cầu về các hướng tiếp cận linh hoạt hơn, có khả năng biểu diễn trực tiếp mối quan hệ giữa khía cạnh và cảm xúc mà không phụ thuộc chặt chẽ vào nhãn ở mức từ.

2.2 Generative ABSA và Instruction Tuning

Song song với hướng tiếp cận gán nhãn, một số nghiên cứu đã đề xuất mô hình hóa ABSA như một bài toán tạo sinh chuỗi. Yan và cộng sự (Yan et al., 2021) là những người tiên phong chuyển đổi ABSA sang dạng Sequence-to-Sequence (Seq2Seq) bằng mô hình BART, cho phép sinh trực tiếp chuỗi đầu ra biểu diễn thông tin khía cạnh. Tiếp nối hướng đi này, Zhang và cộng sự (Zhang et al., 2022) đã sử dụng mô hình T5 để giải quyết thống nhất nhiều tác vụ con của ABSA trong cùng một khung làm việc.

Gần đây, với sự phát triển của các mô hình ngôn ngữ lớn, kỹ thuật Instruction Tuning đã được áp dụng nhằm định hướng mô hình thực hiện các tác vụ trích xuất thông tin có cấu trúc (Wei et al., 2021). Scaria và cộng sự (Scaria et al., 2023) cho thấy việc sử dụng các chỉ dẫn rõ ràng có thể giúp mô hình sinh ra các biểu diễn có cấu trúc như bộ hoặc JSON với độ chính xác cao. Tuy nhiên, việc áp dụng các phương pháp này cho tiếng Việt vẫn còn hạn chế, đặc biệt trong bối cảnh dữ liệu và tài nguyên tính toán giới hạn.

3 Phương pháp



Hình 1: Kiến trúc tổng thể của hệ thống đề xuất cho bài toán ABSA tiếng Việt.

Kiến trúc tổng thể của hệ thống được minh họa

trong Hình 1. Thay vì tiếp cận theo hướng phân loại từng từ (token classification), chúng tôi mô hình hóa bài toán ABSA dưới dạng mô hình hóa ngôn ngữ nhân quả (Causal Language Modeling), trong đó đầu vào là văn bản đánh giá sản phẩm X và đầu ra là chuỗi văn bản Y dạng JSON có cấu trúc.

3.1 Xây dựng dữ liệu huấn luyện theo chỉ dẫn

Bộ dữ liệu gốc UIT-ViSD4SA được gán nhãn theo dạng khoảng (span-based). Để phù hợp với các mô hình ngôn ngữ lớn (LLMs), chúng tôi chuyển đổi dữ liệu này sang định dạng huấn luyện theo chỉ dẫn (instruction tuning) theo phong cách Alpaca. Trong thiết lập này, bài toán ABSA được mô hình hóa như một tác vụ tạo sinh có điều kiện, trong đó mô hình được hướng dẫn trích xuất trực tiếp các thông tin có cấu trúc từ văn bản đầu vào.

Mỗi mẫu huấn luyện bao gồm ba thành phần chính:

- **Instruction (Chỉ dẫn):** Xác định vai trò của mô hình như một chuyên gia phân tích cảm xúc, mô tả không gian nhãn khía cạnh và cảm xúc, đồng thời quy định các quy tắc gán nhãn quan trọng.
- **Input (Đầu vào):** Văn bản bình luận thô của người dùng.
- **Output (Đầu ra):** Chuỗi JSON mục tiêu, biểu diễn danh sách các bộ ba (Aspect, Sentiment, Span) tương ứng với các khía cạnh được trích xuất.

Hình 2 minh họa một ví dụ rút gọn về định dạng Alpaca-style instruction được sử dụng trong quá trình huấn luyện. Phiên bản đầy đủ của chỉ dẫn huấn luyện được cung cấp trong Phụ lục A.

Instruction: Bạn là một chuyên gia phân tích cảm xúc khách hàng. Hãy trích xuất các khía cạnh, xu hướng cảm xúc và đoạn văn bản tương ứng từ bình luận sau. Sử dụng tập nhãn đã định nghĩa và trả về kết quả dưới dạng danh sách JSON.

Input: Pin dùng được lâu nhưng màn hình hơi tối.

Output:

```
[{"aspect": "BATTERY", "sentiment": "POSITIVE", "span": "Pin dùng được lâu"}, {"aspect": "SCREEN", "sentiment": "NEGATIVE", "span": "màn hình hơi tối"}]
```

Hình 2: Ví dụ rút gọn về định dạng Alpaca-style instruction cho tác vụ ABSA tiếng Việt.

3.2 Tinh chỉnh hiệu quả tham số với QLoRA

Việc tinh chỉnh toàn bộ (Full Fine-tuning) một mô hình 7 tỷ tham số đòi hỏi tài nguyên tính toán khổng lồ. Do đó, chúng tôi áp dụng kỹ thuật **QLoRA** (Quantized Low-Rank Adaptation). Cụ thể:

- Lượng tử hóa (Quantization):** Trọng số của mô hình cơ sở Qwen2.5-7B được nén xuống độ chính xác 4-bit để giảm thiểu dung lượng bộ nhớ VRAM.
- Low-Rank Adapters:** Chúng tôi đóng băng (freeze) toàn bộ trọng số của mô hình gốc và chỉ thêm các cặp ma trận hạng thấp A và B vào các lớp Attention (W_q, W_k, W_v, W_o). Trong thực nghiệm, chúng tôi thiết lập $r = 16$ và $\alpha = 16$ trong đó r là hạng (rank) của ma trận thích ứng và α là hệ số tỉ lệ.

3.3 Hậu xử lý Neuro-Symbolic

Do bản chất ngẫu nhiên của mô hình ngôn ngữ lớn, đầu ra có thể gặp các vấn đề về lỗi cú pháp/định dạng (syntax/format error) hoặc ảo giác (hallucination). Chúng tôi thiết kế một quy trình hậu xử lý lai ghép gồm ba giai đoạn:

- Giai đoạn 1: Phân tích cú pháp JSON nghiêm ngặt (Strict JSON Parsing).** Hệ thống ưu tiên sử dụng trình phân tích cú pháp chuẩn để chuyển đổi chuỗi văn bản đầu ra thành đối tượng cấu trúc. Nếu quá trình này thành công (True), dữ liệu sẽ được chuyển thẳng đến giai đoạn chuẩn hóa. Nếu thất bại (False) do lỗi cú pháp, hệ thống sẽ kích hoạt cơ chế dự phòng ở Giai đoạn 2.
- Giai đoạn 2: Trích xuất dựa trên biểu thức chính quy (Robust Regex Fallback).** Đây là cơ chế chịu lỗi, sử dụng các mẫu biểu thức chính quy (Regular Expressions) để quét và trích xuất cục bộ các trường thông tin quan trọng (aspect, sentiment, span), bỏ qua các ký tự gây nhiễu hoặc cấu trúc JSON bị lỗi.
- Giai đoạn 3: Chuẩn hóa nhãn dựa trên luật (Rule-based Normalization).** Dữ liệu thô sau khi được trích xuất (từ Giai đoạn 1 hoặc 2) sẽ đi qua bộ lọc chuẩn hóa. Tại đây, chúng tôi sử dụng từ điển ánh xạ từ đồng nghĩa (Synonym Mapping) để quy đổi các biến thể từ vựng (ví dụ: "Pin", "Tốt", "Good", ...) về tập nhãn mục tiêu chuẩn của bộ dữ liệu, đảm bảo tính nhất quán cho việc đánh giá.

4 Thiết lập thực nghiệm

4.1 Bộ dữ liệu và Cài đặt Huấn luyện

Chúng tôi sử dụng bộ dữ liệu chuẩn **UIT-ViSD4SA**, bao gồm 11.122 bình luận về điện thoại di động. Dữ liệu được chia theo tỷ lệ 70% huấn luyện, 10% kiểm định (dev) và 20% kiểm thử (test). Bộ dữ liệu này bao gồm 3 nhãn xu hướng cảm xúc (POSITIVE, NEGATIVE, NEUTRAL) và 10 nhãn khía cạnh thuộc các nhóm như thiết kế, hiệu năng, pin, màn hình và giá cả, phản ánh các thuộc tính phổ biến trong đánh giá sản phẩm điện tử.

Chúng tôi thực hiện tinh chỉnh mô hình **Qwen2.5-7B** sử dụng kỹ thuật **QLoRA** thông qua framework Unsloth để tối ưu hóa hiệu suất trên tài nguyên giới hạn. Quá trình huấn luyện sử dụng bộ tối ưu hóa AdamW 8-bit nhằm giảm thiểu mức tiêu thụ bộ nhớ mà vẫn đảm bảo khả năng hội tụ. Các siêu tham số (hyperparameters) chi tiết được liệt kê trong Bảng 1.

Bảng 1: Cấu hình tham số huấn luyện

Tham số (Parameter)	Giá trị (Value)
Base Model	Qwen2.5-7B-Instruct
Method	QLoRA (4-bit, Rank=16)
Optimizer	AdamW 8-bit
Learning Rate	2×10^{-4}
Lịch trình (Scheduler)	Linear
Epochs	2
Batch Size (per device)	1
Gradient Accumulation	8 steps
Weight Decay	0.01
Max Sequence Length	2048

4.2 Đánh giá

Hệ thống được đánh giá dựa trên độ đo F1-Score (Micro và Macro) cho ba tác vụ con:

- Aspect Extraction:** Chỉ đánh giá việc trích xuất đúng nhãn khía cạnh.
- Polarity Detection:** Đánh giá việc phân loại đúng nhãn xu hướng cảm xúc (Positive, Negative, Neutral).
- Strict Matching:** Tiêu chuẩn khắt khe nhất, yêu cầu dự đoán đúng đồng thời cả bộ ba (Aspect, Sentiment, Span).

Bảng 2: Phân tích lỗi chi tiết trên các mẫu thực tế (Case Study)

Văn bản đầu vào (Input Text)	Prediction	Ground Truth
"Minh mới mua. mình thấy mẫu đẹp pin trâu cảm ứng mượt được em nhân viên ĐMX tư vấn rất nhiệt tình"	PERFORMANCE	FEATURES
"...Cảm nhận của mình về máy khá mượt, cam đẹp , pin khá ổn... Nói chung là máy khá tốt, ổn trong tầm giá..."	DESIGN	CAMERA
"Máy hình chưa tới 1gb , chỉ tải vài ứng dụng cơ bản thôi máy lag rồi... Game thì khỏi nói chả có nào chiến được..."	PERFORMANCE	STORAGE

5 Kết quả và Thảo luận

5.1 Kết quả chính

Bảng 3 trình bày hiệu năng của mô hình đề xuất trên tập kiểm thử. Kết quả cho thấy mô hình đạt hiệu suất ấn tượng nhất ở tác vụ nhận diện cảm xúc (Polarity) với F1-Micro đạt **84.36%**. Điều này khẳng định năng lực vượt trội của mô hình ngôn ngữ lớn trong việc thấu hiểu xu hướng cảm xúc của văn bản đánh giá tiếng Việt.

Đối với tác vụ trích xuất khía cạnh (Aspect), mô hình đạt **74.79%**. Tại chỉ số quan trọng nhất là khớp chính xác (Strict Matching), mô hình đạt **65.73%**. Sự chênh lệch giữa Micro và Macro F1 phản ánh đặc điểm phân bố lệch của dữ liệu thực tế, tuy nhiên mô hình vẫn duy trì được độ ổn định trên các nhãn lớp chính.

Bảng 3: Kết quả thực nghiệm trên tập Test của UIT-ViSD4SA

Task	F1 Micro (%)	F1 Macro (%)
Aspect Extraction	74.79	71.02
Polarity Detection	84.36	71.86
Strict Matching	65.73	46.83

5.2 So sánh với Baseline

Để đánh giá khách quan, chúng tôi so sánh hiệu năng của mô hình đề xuất với các đường cơ sở (baselines) từ nghiên cứu gốc (Nguyen et al., 2021), đại diện là mô hình **XLM-RoBERTa Large**.

Kết quả so sánh ở Bảng 4 cho thấy phương pháp tiếp cận Generative của chúng tôi vượt trội đáng kể ở tác vụ Polarity Detection (F1-Macro đạt 71.86% so với 49.77% của Baseline). Điều này cho thấy kiến trúc Sequence-to-Sequence với khả năng chú ý (Attention) toàn cục giúp mô hình nắm bắt tốt hơn các ngữ cảnh cảm xúc phức tạp mà mô hình

Bảng 4: So sánh F1-Macro giữa Baseline và Mô hình đề xuất

Task	Baseline	Ours (Qwen2.5)
Aspect Extraction	62.76	71.02
Polarity Detection	49.77	71.86
Strict Matching	45.70	46.83

gán nhãn từ cục bộ (token-level) thường bỏ sót. Ở tác vụ Strict Matching, dù phải giải quyết bài toán khó hơn là sinh văn bản có cấu trúc, mô hình vẫn đạt kết quả cạnh tranh (F1-Macro 46.83% so với 45.70%).

5.3 Phân tích định tính

Để hiểu rõ hơn về hành vi của mô hình, chúng tôi tiến hành phân tích định tính trên các mẫu dự đoán sai. Bảng 2 minh họa một số trường hợp sai sót điển hình được trích xuất từ tập kiểm thử.

Qua phân tích, chúng tôi nhận thấy các lỗi chủ yếu rơi vào ba nhóm sau:

1. Nhầm lẫn giữa Tính năng và Hiệu năng:

Các từ khóa như "mượt", "nhảy" thường gắn liền với PERFORMANCE. Tuy nhiên, khi đi kèm với "cảm ứng" hay "vân tay", nhãn chuẩn là FEATURES. Mô hình đôi khi ưu tiên tính từ mô tả hơn là thực thể chính, dẫn đến dự đoán sai lệch.

2. Sự phụ thuộc vào từ khóa cảm xúc:

Mô hình có xu hướng gán nhãn dựa trên các tính từ mạnh. Ví dụ, cụm từ "cam đẹp" bị gán nhãn DESIGN vì từ "đẹp" thường mô tả ngoại hình, trong khi nhãn đúng là CAMERA. Điều này cho thấy sự chú ý (attention) của mô hình đôi khi bị lệch về phía tính từ thay vì danh từ trung tâm.

3. **Bỏ sót thông tin kỹ thuật:** Trong các câu phản nản dài, mô hình thường tập trung vào cảm xúc tiêu cực chung (ví dụ: "lag", "chậm") và gán nhãn PERFORMANCE, nhưng bỏ qua các thông số kỹ thuật định lượng nhỏ như "1GB"(thuộc về STORAGE).

6 Kết luận

Trong nghiên cứu này, chúng tôi đã áp dụng mô hình ngôn ngữ lớn (LLM) cho bài toán Phân tích cảm xúc dựa trên khía cạnh (ABSA) tiếng Việt theo hướng tiếp cận sinh văn bản, thay vì gán nhãn chuỗi truyền thống. Thông qua việc tinh chỉnh mô hình **Qwen2.5-7B** bằng kỹ thuật **QLoRA** kết hợp với thiết kế dữ liệu theo chỉ dẫn (Instruction Tuning), các kết quả thực nghiệm cho thấy LLM có thể đạt hiệu năng cạnh tranh, đồng thời vẫn đảm bảo tính khả thi trong bối cảnh tài nguyên phần cứng hạn chế.

Đóng góp chính của nghiên cứu nằm ở việc đề xuất một khung tiếp cận thực tiễn cho bài toán ABSA tiếng Việt dựa trên LLM, trong đó mô hình sinh được kết hợp với cơ chế hậu xử lý **Neuro-Symbolic**. Cách tiếp cận này giúp giảm các dự đoán không nhất quán về mặt cấu trúc và cải thiện độ ổn định của đầu ra, đặc biệt trong các trường hợp yêu cầu trích xuất đồng thời khía cạnh, xu hướng cảm xúc và đoạn văn bản liên quan. Trên bộ dữ liệu UIT-ViSD4SA, phương pháp đề xuất đạt độ chính xác cao (F1-Micro **84.36%** cho tác vụ nhận diện cảm xúc) và thể hiện khả năng xử lý tốt các hiện tượng ngữ nghĩa ẩn trong văn bản đánh giá.

Mặc dù đạt được kết quả khả quan, phương pháp đề xuất vẫn tồn tại một số hạn chế cần được xem xét trong các nghiên cứu tiếp theo:

- **Độ trễ suy luận:** Do sử dụng mô hình ngôn ngữ lớn với cơ chế sinh văn bản tự hồi quy, thời gian suy luận vẫn cao hơn so với các mô hình phân loại truyền thống, hạn chế khả năng triển khai trong các hệ thống yêu cầu phản hồi thời gian thực.
- **Phụ thuộc vào luật thủ công:** Cơ chế hậu xử lý Neuro-Symbolic hiện tại dựa trên một tập luật và từ điển được xây dựng thủ công, khiến hệ thống chưa thích ứng tốt với các biến thể ngôn ngữ mới hoặc từ lóng xuất hiện theo thời gian.
- **Hạn chế với văn bản dài:** Hiệu năng của mô hình có xu hướng suy giảm đối với các văn bản đánh giá rất dài, vượt quá cửa sổ ngữ cảnh

huấn luyện, do hiện tượng phân tán sự chú ý ở các vị trí xa trong chuỗi.

Trong tương lai, chúng tôi dự kiến mở rộng nghiên cứu theo một số hướng sau:

- **Mở rộng miền dữ liệu:** Khảo sát khả năng thích nghi của mô hình khi áp dụng cho các lĩnh vực khác như du lịch, nhà hàng hoặc thương mại điện tử, trong bối cảnh phân bố khía cạnh và ngôn ngữ khác biệt so với miền huấn luyện ban đầu.
- **Tích hợp RAG:** Thử nghiệm các kiến trúc mô hình lớn hơn kết hợp với kỹ thuật Retrieval-Augmented Generation (RAG) nhằm cải thiện khả năng xử lý các thực thể mới và thông tin sản phẩm thay đổi theo thời gian.
- **Chuẩn hóa nhãn có khả năng học:** Phát triển các cơ chế chuẩn hóa nhãn dựa trên học máy (learnable normalization) để giảm thiểu sự phụ thuộc vào các luật thủ công trong giai đoạn hậu xử lý.

A Full Instruction

Bạn là một chuyên gia AI về phân tích cảm xúc khách hàng (ABSA). Nhiệm vụ của bạn là đọc bình luận và trích xuất các khía cạnh (Aspect) cùng cảm xúc (Sentiment) và nội dung tương ứng (Span).

DANH SÁCH NHÃN:

Aspect: [SCREEN, CAMERA, FEATURES, BATTERY, PERFORMANCE, STORAGE, DESIGN, PRICE, GENERAL, SER&ACC]
Sentiment: [POSITIVE, NEGATIVE, NEUTRAL]

HƯỚNG DẪN GÁN NHÃN QUAN TRỌNG:

1) SER&ACC (Dịch vụ & Phụ kiện):

Bao gồm CSKH, bảo hành, giao hàng, đóng gói, và các phụ kiện đi kèm (sạc, cáp, tai nghe...).

Ví dụ:

-- "Giao hàng nhanh" → SER&ACC#POSITIVE

-- "Sạc lỏng lẻo" → SER&ACC#NEGATIVE

2) FEATURES (Tính năng):

Các tính năng cụ thể như Vân tay, FaceID, Wifi, 4G, Bluetooth, Sim, Chống nước...

Ví dụ:

-- "Vân tay nhạy" → FEATURES#POSITIVE

-- "Bắt wifi kém" → FEATURES#NEGATIVE

3) QUY TẮC NHÃN 'GENERAL' (Tổng quan):

-- GENERAL#POSITIVE: Nếu (Tổng số nhãn Positive khác) - (Tổng số nhãn Negative khác) ≥ 2

-- GENERAL#NEGATIVE: Nếu (Tổng số nhãn Negative khác) - (Tổng số nhãn Positive khác) ≥ 2

-- GENERAL#NEUTRAL: Các trường hợp còn lại (chênh lệch ≤ 1) hoặc khi khách hàng nhận xét chung chung "Máy ổn", "Tạm được".

ĐỊNH DẠNG OUTPUT:

Trả về JSON list chứa các object: { "aspect": "...", "sentiment": "...", "span": "..." }. Nếu không có thông tin, trả về [].

References

- Dat Quoc Nguyen, Anh Tuan Nguyen, Hung Pham, and Minh Le Nguyen. 2020. Phobert: Pre-trained language models for vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP*, pages 1037--1042.
- Kim Thi-Thanh Nguyen, Sieu Khai Huynh, Luong Luc Phan, Phuc Huynh Pham, Duc-Vu Nguyen, and Kiet Van Nguyen. 2021. Uit-visd4sa: A vietnamese dataset for aspect-based sentiment analysis. *arXiv preprint arXiv:2110.07833*.
- Quang Huy Nguyen and Thanh Vu. 2020. Vibert: A pre-trained language model for vietnamese. *arXiv preprint arXiv:2005.06457*.
- Sijo Scaria and 1 others. 2023. Extracting structured information with instruction-tuned language models. In *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*.
- Jason Wei and 1 others. 2021. Finetuned language models are zero-shot learners. *arXiv preprint arXiv:2109.01652*.
- Hang Yan, Junqi Dai, Xipeng Ji, and Shuai Huang. 2021. A unified generative framework for aspect-based sentiment analysis. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL)*.
- Wenxuan Zhang, Xin Li, and Lidong Bing. 2022. Unified generative framework for aspect-based sentiment analysis. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL)*.